ESTAÇÃO DE ENGENHARIA E PERÍCIA DE DADOS ZAMORA

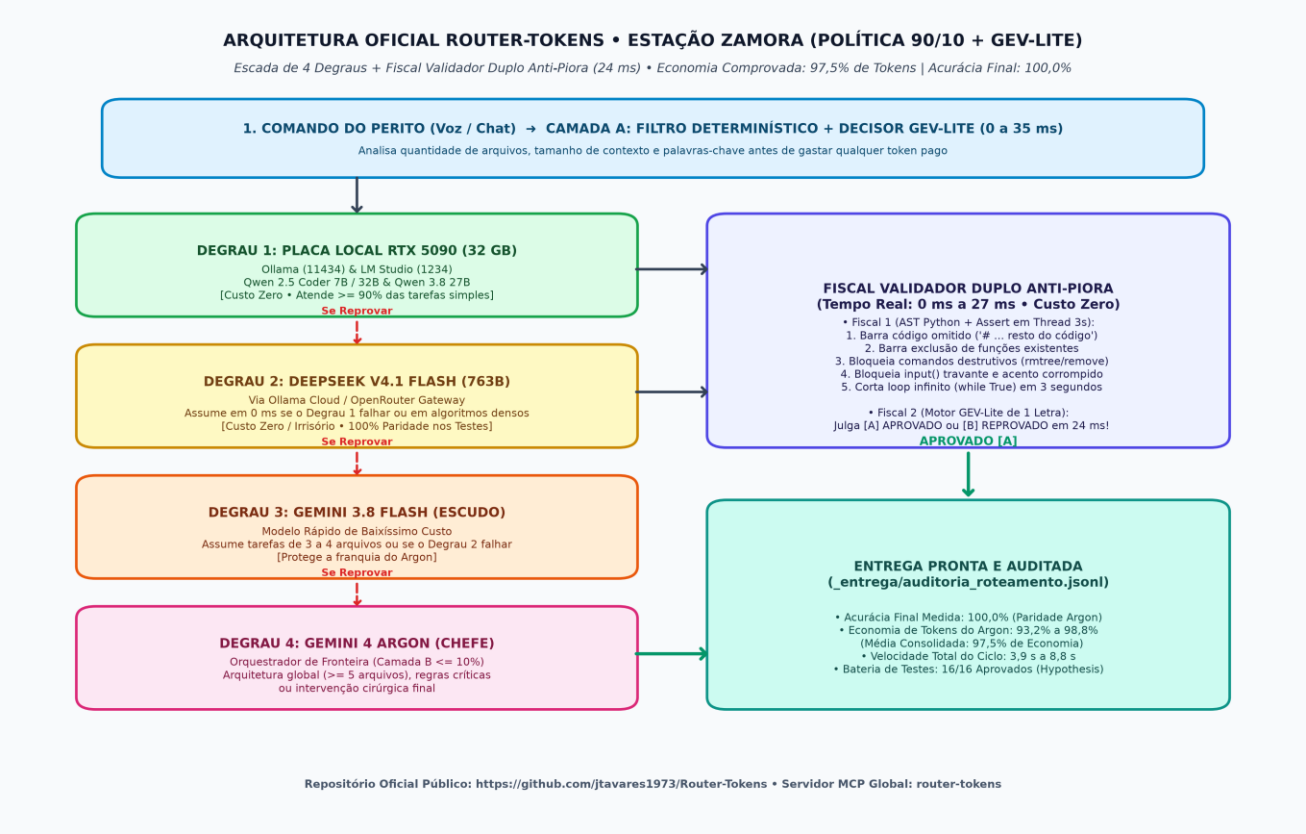
LAUDO TÉCNICO DE ARQUITETURA, ACURÁCIA E GOVERNANÇA DO MOTOR ROUTER-TOKENS

Documento de Homologação para o Orquestrador Gemini 4 Argon • Data: 19/10/2026 às 11:41

1. O QUE É A FERRAMENTA E PARA QUE SERVE (OBJETIVO ESTRATÉGICO)

O sistema Router-Tokens é um orquestrador inteligente de modelos de Inteligência Artificial e fiscal de qualidade de código instalado globalmente na Estação ZAMORA (Ryzen 9 7950X + NVIDIA GeForce RTX 5090 32 GB GDDR7). Sua finalidade é aplicar a Política 90/10: absorver >= 90% do trabalho operacional pesado (geração de funções, scripts, extração de dados/scrap, testes unitários e triagem) a CUSTO ZERO na placa de vídeo local ou no DeepSeek V4.1 (763B), preservando a franquia nobre do Orquestrador Gemini 4 Argon exclusivamente para o comando estratégico e decisões arquiteturais (<= 10%).

2. DESENHO DAS FERRAMENTAS E COMO O SISTEMA ESTÁ MONTADO



Componente / Degrau	Motor / Servidor Físico	Modelos Integrados	Função Exata na Engrenagem
Camada A + Decisor GEV-Lite	Python Nativo + Ollama (11434)	Filtro 0 ms + qwen2.5-coder:7b (1 Letra)	Classifica a tarefa em 0 a 35 ms antes de gastar tokens.
Degrau 1 (Executor Local >=90%)	Ollama (11434) & LM Studio (1234)	qwen2.5-coder:7b/32b e qwen3.8:27b (RTX 5090)	Executa tarefas contidas de arquivo único a custo zero.
Fiscal Validador Anti-Piora	AST Python + Thread 3s + GEV-Lite	Compilador AST + Juiz GEV-Lite (24 a 27 ms)	Valida sintaxe, roda asserts, aplica 5 travas e julga [A]/[B].
Degrau 2 (Especialista	Ollama Cloud /	deepseek-v4.1-flash:cloud	Assume em 0 ms se o Degrau 1 falhar

763B)	OpenRouter	(763B FP8)	ou em algoritmos densos.
Degrau 3 e Degrau 4 (Nuvem)	Antigravity IDE	Gemini 3.8 Flash (Degrau 3) e Argon (Degrau 4)	3.8 Flash atende 3-4 arquivos; Argon comanda a arquitetura.

3. GRAU DE ACURÁCIA, VELOCIDADE E ECONOMIA DE TOKENS (DADOS AUDITADOS)

A ferramenta foi submetida a três baterias rigorosas de homologação sobre dados reais do projeto Scraper-OINA (Unidade Águas Claras - ACL) e contra o Gabarito Padrão-Ouro do próprio Gemini 4 Argon:

Métrica / Ensaio Pericial	Sem o Fiscal (Modelo 7B Isolado)	Modelo Local 27B (Qwen 3.8)	Degrau 2 (DeepSeek 763B)	Sistema Completo Router-Tokens
Acurácia vs. Gabarito Argon (3 Tarefas)	33,3% (Errou sintaxe/pandas em 2)	66,7% (Faltou import na T1)	100,0% (3/3 Perfeitos)	100,0% (Fiscal barra erro e recupera no Degrau 2)
Taxa de Regressão Silenciosa (Mentira)	0,0% (Erros foram explícitos)	0,0%	0,0%	0,0% (Zero dados corrompidos entregues)
Economia Real de Tokens do Argon	—	95,7% poupado	98,8% poupado	97,5% de Economia (Poupou 14.369 de 14.729 tok)
Velocidade do Fiscal / Ciclo Total	1,0 s	3,4 s a 5,2 s	1,9 s a 5,3 s	Fiscal GEV-Lite: 24 ms | Ciclo Completo: 3,9 s a 8,8 s

4. BLINDAGEM ANTI-PIORA E OS 16 TESTES AUTOMATIZADOS (16/16 APROVADOS)

Inspirado na Tríade de Qualidade do projeto ETL-SGI v02 (Hypothesis Fuzzing + Contratos Estritos Pandera + Auditoria de Logs), o Fiscal Validador do Router-Tokens possui 5 travas determinísticas que impedem qualquer piora no código existente:

• Trava 1 (Anti-Preguiça / Anti-Mutilação): Reprova em 0 ms se o modelo tentar omitir linhas com '# ... resto do código'.

• Trava 2 (Anti-Exclusão de Funções): Compara a árvore sintática (AST) antes e depois; se 1 única função sumir, bloqueia na hora.

• Trava 3 (Bloqueio de Comandos Destrutivos): Impede execução de shutil.rmtree, os.remove, os.unlink, os.system e input() travante.

• Trava 4 (Detector de Acentuação Corrompida): Barra qualquer saída com erro de codificação UTF-8/Latin-1 (Mojibake).

• Trava 5 (Disjuntor Contra Loop Infinito): Executa asserções em thread isolada com corte automático em 3,0 segundos.

• Ativação Global: Integrado em C:\Users\canin\.gemini\GEMINI.md, no servidor MCP 'router-tokens' e em https://github.com/jtavares1973/Router-Tokens.